

eda

February 13, 2023

```
[19]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

```
[20]: df = pd.read_csv("data_prep.csv")
```

```
[21]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5162 entries, 0 to 5161
Data columns (total 49 columns):
 #   Column
Non-Null Count  Dtype
---  -
0   Unnamed: 0
5162 non-null   int64
1   Age
5162 non-null   float64
2   Sortie Positif
5162 non-null   int64
3   temps_psp
5162 non-null   float64
4   temps_pe
5162 non-null   float64
5   temps_fin
5162 non-null   float64
6   Civilité_Madame
5162 non-null   float64
7   Civilité_Monsieur
5162 non-null   float64
8   Type 1er RDV_Entretien individuel
5162 non-null   float64
9   Type 1er RDV_Webcam
5162 non-null   float64
10  Taille dernière entreprise :_500 salariés et plus
5162 non-null   float64
```

11 Taille dernière entreprise :_De 10 à 49 salariés
 5162 non-null float64
 12 Taille dernière entreprise :_De 50 à 499 salariés
 5162 non-null float64
 13 Taille dernière entreprise :_Moins de 10 salariés
 5162 non-null float64
 14 Taille dernière entreprise :_nan
 5162 non-null float64
 15 Secteur_AGRICULTURE ET PÊCHE, ESPACES NATURELS ET ESPACES VERTS, SOINS AUX ANIMAUX
 5162 non-null float64
 16 Secteur_ARTS ET FACONNAGE D'OUVRAGES D'ART
 5162 non-null float64
 17 Secteur_BANQUE, ASSURANCE, IMMOBILIER
 5162 non-null float64
 18 Secteur_COMMERCE, VENTE ET GRANDE DISTRIBUTION
 5162 non-null float64
 19 Secteur_COMMUNICATION, MEDIA ET MULTIMEDIA
 5162 non-null float64
 20 Secteur_CONSTRUCTION, BÂTIMENT ET TRAVAUX PUBLICS
 5162 non-null float64
 21 Secteur_HÔTELLERIE- RESTAURATION TOURISME LOISIRS ET ANIMATION
 5162 non-null float64
 22 Secteur_INDUSTRIE
 5162 non-null float64
 23 Secteur_INSTALLATION ET MAINTENANCE
 5162 non-null float64
 24 Secteur_SANTE
 5162 non-null float64
 25 Secteur_SERVICES A LA PERSONNE ET A LA COLLECTIVITE
 5162 non-null float64
 26 Secteur_SPECTACLE
 5162 non-null float64
 27 Secteur_SUPPORT A L'ENTREPRISE
 5162 non-null float64
 28 Secteur_TRANSPORT ET LOGISTIQUE
 5162 non-null float64
 29 Secteur_nan
 5162 non-null float64
 30 Code Prescripteur_1
 5162 non-null float64
 31 Code Prescripteur_26
 5162 non-null float64
 32 Code Prescripteur_27
 5162 non-null float64
 33 Code Prescripteur_38
 5162 non-null float64
 34 Code Prescripteur_42
 5162 non-null float64

```

35 Code Prescripteur_54
5162 non-null float64
36 Code Prescripteur_61
5162 non-null float64
37 Code Prescripteur_63
5162 non-null float64
38 Code Prescripteur_67
5162 non-null float64
39 Code Prescripteur_68
5162 non-null float64
40 Code Prescripteur_69
5162 non-null float64
41 Code Prescripteur_73
5162 non-null float64
42 Code Prescripteur_75
5162 non-null float64
43 Code Prescripteur_76
5162 non-null float64
44 Code Prescripteur_78
5162 non-null float64
45 Code Prescripteur_92
5162 non-null float64
46 Code Prescripteur_93
5162 non-null float64
47 Code Prescripteur_94
5162 non-null float64
48 Code Prescripteur_95
5162 non-null float64
dtypes: float64(47), int64(2)
memory usage: 1.9 MB

```

```
[22]: df = df.drop(columns="Unnamed: 0")
```

```
[23]: df.head()
```

```
[23]:
```

	Age	Sortie Positif	temps_psp	temps_pe	temps_fin	Civilité_Madame \
0	0.632653	0	0.095385	0.260073	0.480740	1.0
1	0.224490	0	0.043077	0.113553	0.546995	1.0
2	0.918367	0	0.046154	0.194139	0.408320	1.0
3	0.816327	1	0.064615	0.102564	0.303544	0.0
4	0.795918	1	0.052308	0.391941	0.543914	1.0

	Civilité_Monsieur	Type 1er RDV_Entretien individuel	Type 1er RDV_Webcam \
0	0.0	1.0	0.0
1	0.0	1.0	0.0
2	0.0	1.0	0.0
3	1.0	1.0	0.0

4	0.0	1.0	0.0
---	-----	-----	-----

	Taille dernière entreprise :_500 salariés et plus ... \
0	0.0 ...
1	0.0 ...
2	0.0 ...
3	0.0 ...
4	0.0 ...

	Code Prescripteur_68	Code Prescripteur_69	Code Prescripteur_73 \
0	0.0	0.0	0.0
1	0.0	0.0	0.0
2	0.0	0.0	0.0
3	0.0	0.0	0.0
4	0.0	0.0	0.0

	Code Prescripteur_75	Code Prescripteur_76	Code Prescripteur_78 \
0	0.0	0.0	0.0
1	0.0	0.0	0.0
2	0.0	0.0	0.0
3	0.0	0.0	0.0
4	0.0	0.0	0.0

	Code Prescripteur_92	Code Prescripteur_93	Code Prescripteur_94 \
0	0.0	0.0	0.0
1	0.0	0.0	0.0
2	0.0	0.0	0.0
3	0.0	0.0	0.0
4	0.0	0.0	0.0

	Code Prescripteur_95
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0

[5 rows x 48 columns]

```
[24]: df.describe()
```

	Age	Sortie Positif	temps_psp	temps_pe	temps_fin \
count	5162.000000	5162.000000	5162.000000	5162.000000	5162.000000
mean	0.533336	0.245641	0.106407	0.156459	0.481013
std	0.227237	0.430508	0.063542	0.099806	0.095463
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.346939	0.000000	0.064615	0.095238	0.445300

50%	0.530612	0.000000	0.095385	0.124542	0.500770
75%	0.734694	0.000000	0.132308	0.179487	0.534669
max	1.000000	1.000000	1.000000	1.000000	1.000000

	Civilité_Madame	Civilité_Monsieur	Type 1er RDV_Entretien individuel \
count	5162.000000	5162.000000	5162.000000
mean	0.510074	0.489926	0.901976
std	0.499947	0.499947	0.297376
min	0.000000	0.000000	0.000000
25%	0.000000	0.000000	1.000000
50%	1.000000	0.000000	1.000000
75%	1.000000	1.000000	1.000000
max	1.000000	1.000000	1.000000

	Type 1er RDV_Webcam	Taille dernière entreprise :_500 salariés et plus \
count	5162.000000	5162.000000
mean	0.098024	0.019372
std	0.297376	0.137843
min	0.000000	0.000000
25%	0.000000	0.000000
50%	0.000000	0.000000
75%	0.000000	0.000000
max	1.000000	1.000000

	...	Code Prescripteur_68	Code Prescripteur_69	Code Prescripteur_73 \
count	...	5162.000000	5162.000000	5162.000000
mean	...	0.014723	0.043975	0.030608
std	...	0.120453	0.205060	0.172271
min	...	0.000000	0.000000	0.000000
25%	...	0.000000	0.000000	0.000000
50%	...	0.000000	0.000000	0.000000
75%	...	0.000000	0.000000	0.000000
max	...	1.000000	1.000000	1.000000

	Code Prescripteur_75	Code Prescripteur_76	Code Prescripteur_78 \
count	5162.000000	5162.000000	5162.000000
mean	0.129601	0.049981	0.100155
std	0.335896	0.217926	0.300236
min	0.000000	0.000000	0.000000
25%	0.000000	0.000000	0.000000
50%	0.000000	0.000000	0.000000
75%	0.000000	0.000000	0.000000
max	1.000000	1.000000	1.000000

	Code Prescripteur_92	Code Prescripteur_93	Code Prescripteur_94 \
count	5162.000000	5162.000000	5162.000000
mean	0.039907	0.114103	0.117978

std	0.195760	0.317967	0.322613
min	0.000000	0.000000	0.000000
25%	0.000000	0.000000	0.000000
50%	0.000000	0.000000	0.000000
75%	0.000000	0.000000	0.000000
max	1.000000	1.000000	1.000000

	Code Prescripteur_95
count	5162.000000
mean	0.059667
std	0.236891
min	0.000000
25%	0.000000
50%	0.000000
75%	0.000000
max	1.000000

[8 rows x 48 columns]

```
[25]: df.groupby("Sortie Positif").count()
```

```
[25]:
```

	Age	temps_psp	temps_pe	temps_fin	Civilité_Madame \
Sortie Positif					
0	3894	3894	3894	3894	3894
1	1268	1268	1268	1268	1268

	Civilité_Monsieur	Type 1er RDV_Entretien individuel \
Sortie Positif		
0	3894	3894
1	1268	1268

	Type 1er RDV_Webcam \
Sortie Positif	
0	3894
1	1268

	Taille dernière entreprise :_500 salariés et plus \
Sortie Positif	
0	3894
1	1268

	Taille dernière entreprise :_De 10 à 49 salariés ... \
Sortie Positif	
0	3894 ...
1	1268 ...

	Code Prescripteur_68	Code Prescripteur_69 \
--	----------------------	------------------------

Sortie Positif	Code Prescripteur_73	Code Prescripteur_75 \
0	3894	3894
1	1268	1268

Sortie Positif	Code Prescripteur_76	Code Prescripteur_78 \
0	3894	3894
1	1268	1268

Sortie Positif	Code Prescripteur_92	Code Prescripteur_93 \
0	3894	3894
1	1268	1268

Sortie Positif	Code Prescripteur_94	Code Prescripteur_95
0	3894	3894
1	1268	1268

[2 rows x 47 columns]

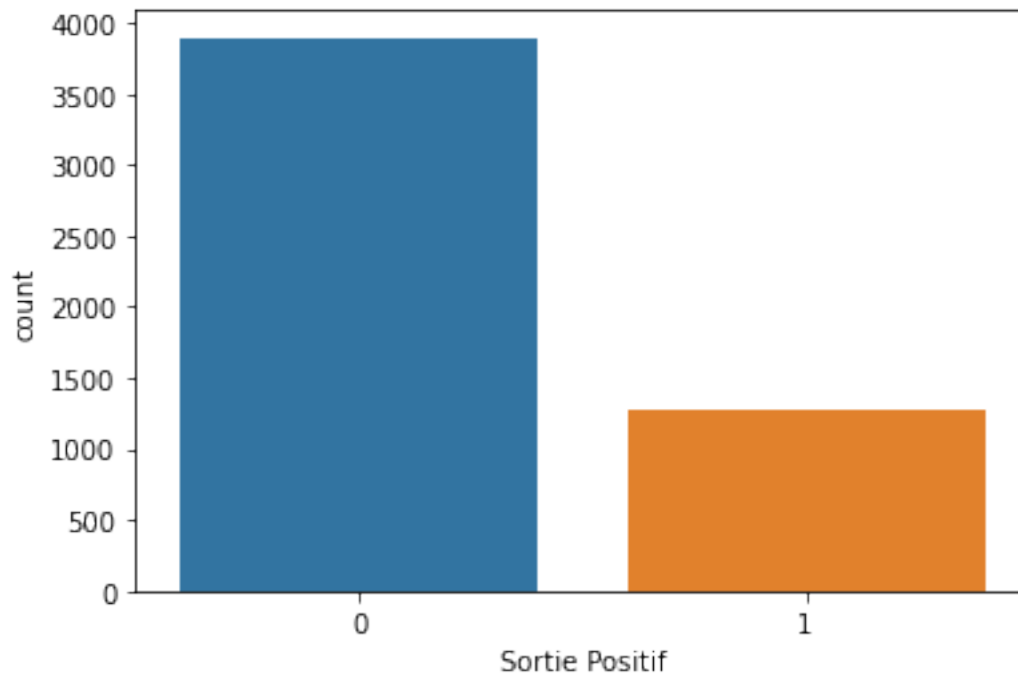
```
[26]: 1268/3894
```

```
[26]: 0.3256291730868002
```

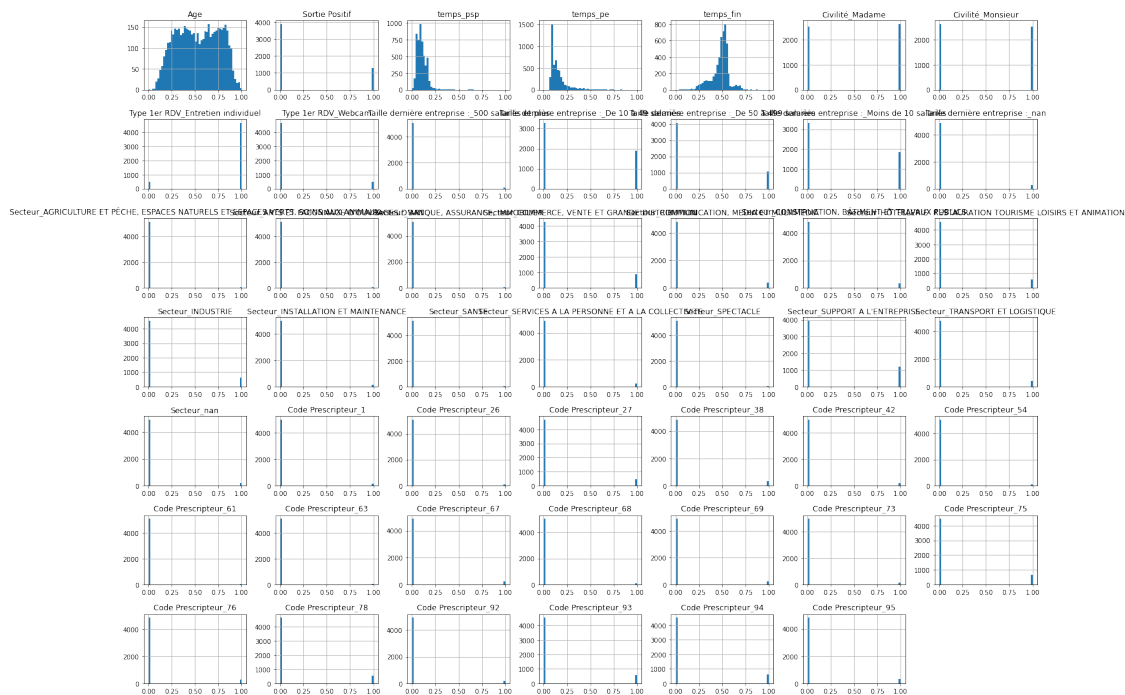
```
[27]: sns.countplot(df['Sortie Positif'])
```

```
/home/n_fuentes/.local/lib/python3.8/site-packages/seaborn/_decorators.py:36:
FutureWarning: Pass the following variable as a keyword arg: x. From version
0.12, the only valid positional argument will be `data`, and passing other
arguments without an explicit keyword will result in an error or
misinterpretation.
warnings.warn(
```


```
[27]: <AxesSubplot:xlabel='Sortie Positif', ylabel='count'>
```




```
[28]: df.hist(bins=50, figsize=(20,15))
plt.tight_layout()
plt.show()
```



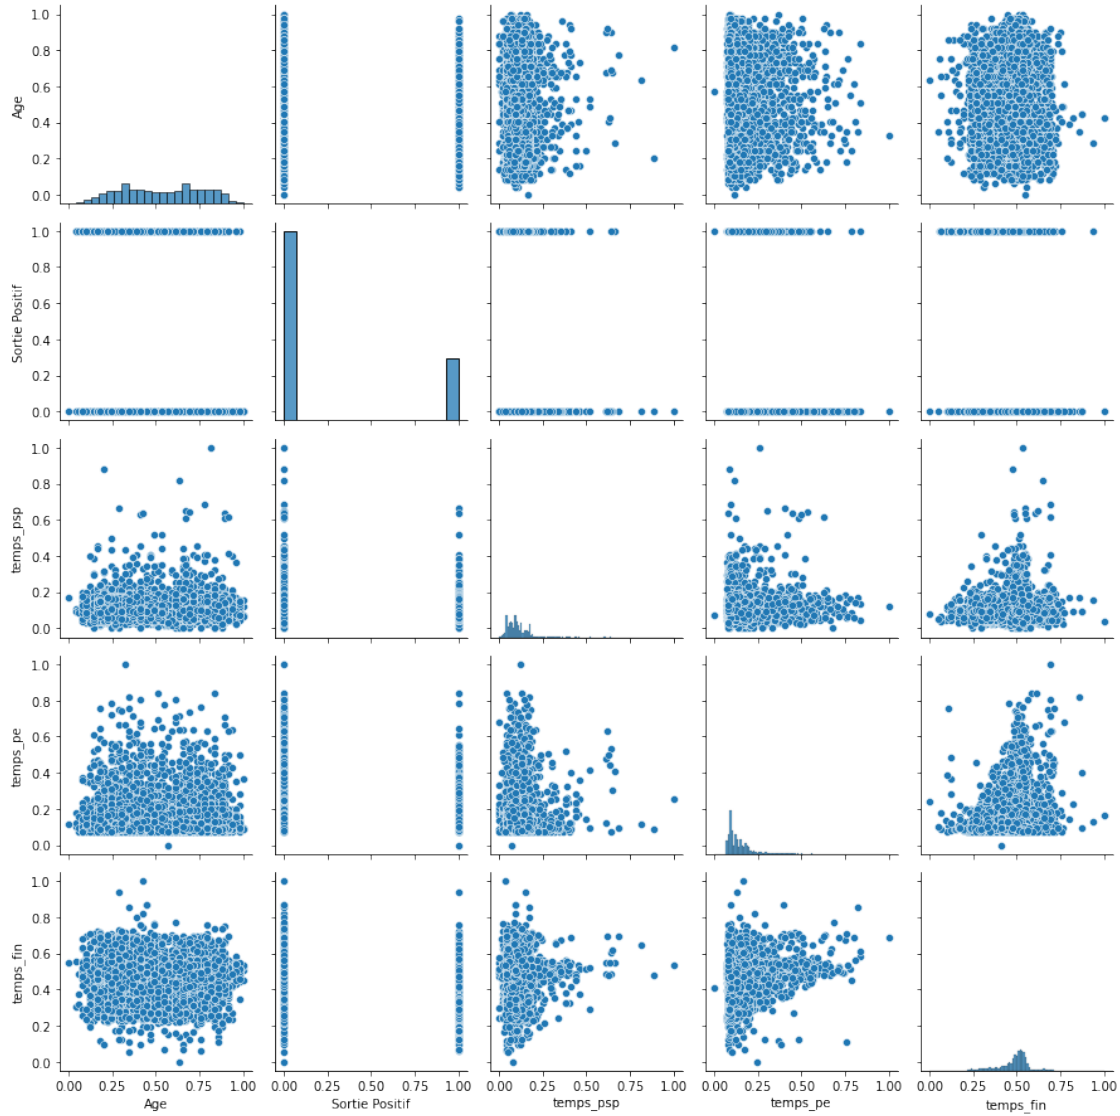

```
[35]: df[["Age", "Sortie_␣
↪Positif", "temps_psp", "temps_pe", "temps_fin"]].
↪hist(bins=50, figsize=(20,15))
plt.tight_layout()
plt.show()
```




```
[29]: sns.pairplot(df)
plt.show()
```




```
[30]: sns.pairplot(df[["Age", "Sortie_Positif", "temps_psp", "temps_pe", "temps_fin"]])  
plt.tight_layout()  
plt.show()
```



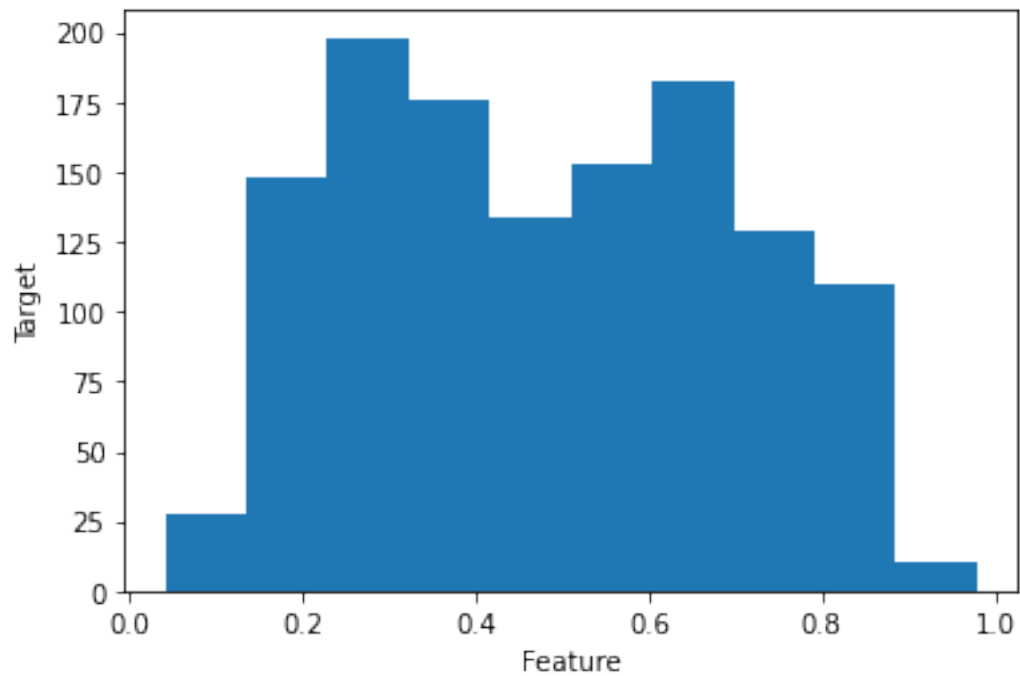
```
[31]: corr = df.corr()
plt.figure(figsize=(20,15))
sns.heatmap(corr, annot=True).set_title('Correlation Heatmap',
fontdict={'fontsize':12}, pad=12)
plt.show()
```



```
[32]: corr = df[["Age", "Sortie_
↳Positif", "temps_psp", "temps_pe", "temps_fin"]].corr()
plt.figure(figsize=(20,15))
sns.heatmap(corr, annot=True).set_title('Correlation Heatmap',
↳fontdict={'fontsize':12}, pad=12)
plt.show()
```



```
[33]: plt.hist(df['Age'].where(df["Sortie Positif"]==1))
plt.xlabel("Feature")
plt.ylabel("Target")
plt.show()
```



```
[34]: plt.hist(df['Age'].where(df["Sortie Positif"]==0))  
plt.xlabel("Feature")  
plt.ylabel("Target")  
plt.show()
```

